Introducción a la Ciencia de Datos - Tarea 1
Grupo 3

Abu Arab, Juan
5.041.245-7

Quincke, Santiago
5.094.032-3

14 de mayo de 2026

1. Código fuente

El código de la tarea se encuentra en el siguiente repositorio de Github: `https://github.com/SQuincke/intro-cd-tarea-1/tree/main`.

2. Parte I

2.1. Parte A

Se hizo un data profiling haciendo queries al dataset y utilizando la biblioteca ydata-profiling. Se detectaron los siguientes campos nulos:

Columna	Cantidad nulos	Porcentaje de nulos
author	11405	37.75
article	1176	2.892
url	141	0.4667
section	10232	33.87
publication	141	0.4667

Cuadro 1: Campos nulos detectados

En el cuadro 1 se observa que hay 141 artículos sin editorial, los cuales fueron eliminados para seguir con el trabajo.

En esta etapa se detectaron los siguientes problemas de calidad:

P1: Hay dos formatos distintos para la columna *date*: 'yyyy-mm-dd' y 'yyyy-mm-dd hh:mm:ss'.

P2: Hay dos columnas *idx* y *article_idx* repetidas (ambas representan el identificador del artículo).

P3: Valores nulos en todas las columnas.

Del dataframe, se obtienen los datos del Cuadro 2, los cuales indican la cantidad de publicaciones por editorial.

De acá en adelante, se trabja con los artículos de los 5 medios con mayor cantidad de artículos publicados; estos son, los artículos de las editoriales *Reuters*, *The New York Times*, *CNBC*, *The Hill* y *People*. Estas 5 editoriales contienen dentro del dataset un total de 18771 artículos, aproximadamente el 62,4 % de todos los artículos del dataset

2.2. Parte B

De la Figura 1, podemos observar que la editorial *Reuters* mantiene una cantidad de artículos sumamente superior a lo largo del tiempo, posicionándose consistentemente como la fuente con mayor número de publicaciones.

Editorial	Cantidad	Porcentaje del total
Reuters	9431	31.36
The New York Times	2840	9.444
CNBC	2623	8.722
The Hill	2349	7.811
People	1528	5.081
CNN	1446	4.808
Refinery 29	1236	4.110
Vice	1154	3.837
Mashable	1045	3.475
Business Insider	660	2.195
The Verge	594	1.975
TechCrunch	568	1.889
TMZ	552	1.836
Vox	549	1.826
Axios	538	1.789
Politico	518	1.723
Washington Post	468	1.556
Buzzfeed News	376	1.250
Gizmodo	329	1.094
Economist	303	1.008
Wired	231	0.7682
Fox News	227	0.7549
Vice News	187	0.6218
New Republic	145	0.4822
Hyperallergic	123	0.4090
New Yorker	52	0.1729

Cuadro 2: Cantidad de artículos por editorial

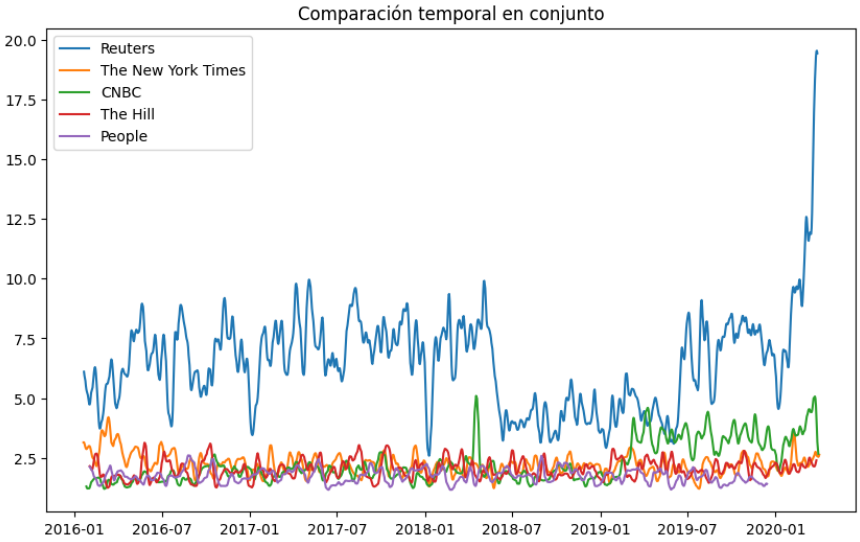

Figura 1: Serie temporal de cantidad de artículos publicados por editorial (con filtro gaussiano aplicado)

Cabe destacar que, durante el año 2018, CNBC presentó un pico en la cantidad de artículos publicados, mientras que *Reuters* experimentó una caída que se prolongó durante casi un año. Durante este período de descenso de *Reuters*, CNBC mostró un crecimiento considerable. Posteriormente, *Reuters* se recuperó sobre comienzos del año 2020, finalizando con un pico aproximadamente tres veces mayor que su media histórica.

Por otro lado, las otras tres editoriales presentan un desempeño considerablemente menor que *Reuters* y relativamente uniforme a lo largo del período analizado.

Por otra parte, la Figura 2 se hizo con el fin de buscar mayores actividades mensuales. En la figura se observa que los primeros tres meses del año tienen una mayor cantidad de artículos publicados para cuatro de las cinco editoriales. Sin embargo, tambiên se observa que el dataset contiene datos hasta el cuarto mes del año 2020 (esto también se puede visualizar en la Figura 1), lo que hace haya un conteo más de artículos para enero, febrero, marzo y unos pocos días de abril, lo que invalida la observación anterior.

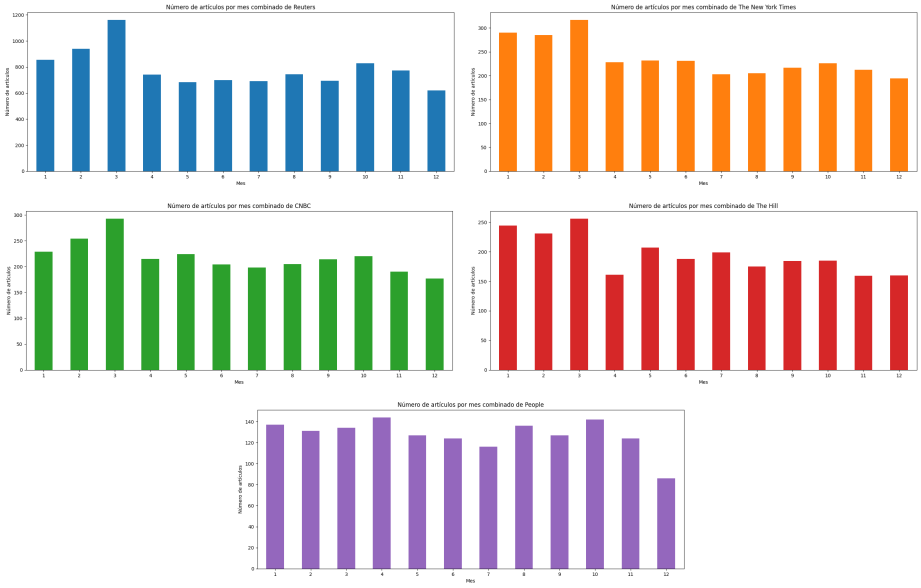

Figura 2: Histograma de comparación mensual de cantidad de artículos publicados acumulado durante los años por editorial

2.3. Parte C

Para la limpieza del texto, primero suplantamos los nombres de las editoriales por *ids*. Esto se debe a que algunos nombres de editoriales son también palabras comunes usadas frecuentemente. Por ejemplo, *people*.

Luego, para crear una lista de caracteres no deseados buscamos todos los no alfabéticos. Se consideró buscar los no alfanuméricos, pero se decidió que los números no cuentan como palabras.

Después, parseamos todos los strings de los artículos a minúsculas, como se sugería en la letra del problema. Esto llevó a crear las columnas *clear text* y *clear text title*; siendo estas las columnas *articles* y *titles* filtradas, en las cuales se incluyen los textos en minúsuclas y se sustituyen los caracteres no deseados por un carácter espacio.

2.4. Parte D

Se concideró que tanto el título como el cuerpo del artículo aportan información relevante sobre el artículo, por lo que se decidió usar ambos, pero manteniéndolos separados porque son tipos de información distintos en la realidad.

2.5. Parte E

Vemos que muchos autores escriben casi exclusivamente para un mismo medio. Esto permite definir una especie de "autores fieles", donde la presencia de determinado autor puede utilizarse como un fuerte indicador de la editorial a la que pertenece el artículo (ver Tabla 3).

Por ejemplo, autores como John Bowden, Rebecca Savransky o Tal Axelrod aparecen únicamente en artículos de *The Hill*, mientras que Alexia Fernandez, Dave Quinn y Stephanie Petit escriben exclusivamente para *People*. De manera similar, *Reuters* y *The New York Times* también presentan autores altamente concentrados en sus respectivas publicaciones.

A partir de la información presentada en el cuadro 3 se exploró la cantidad de autores nulos presentes en el top 5 de publicaciones.

Total de autores nulos en el top 5: 9425.

- Reuters: 6573 autores nulos
- CNBC: 2600 autores nulos
- The Hill: 14 autores nulos
- The New York Times: 237 autores nulos
- People: 1 autor nulo

Autor	**CNBC**	**People**	**Reuters**	**The Hill**	**NYT**
John Bowden	0	0	0	91	0
Field Level Media	0	0	82	0	0
The Associated Press	0	0	0	0	74
Rebecca Savransky	0	0	0	68	0
Alexia Fernandez	0	60	0	0	0
Dave Quinn	0	59	0	0	0
Julia Manchester	0	0	0	57	0
People Staff	0	54	0	0	0
Stephanie Petit	0	51	0	0	0
Tal Axelrod	0	0	0	50	0

Cuadro 3: Autores con mayor cantidad de artículos por publicación

De la misma forma que los autores se asocian fuertemente con un único medio, las URLs también contienen dominios característicos que identifican inmediatamente a la editorial. Reuters utiliza el dominio "reuters", CNBC utiliza "cnbc", mientras que *The New York Times* presenta múltiples subdominios propios como "nytimes", "blogs.nytimes" . Esto evidencia que tanto el autor como la estructura de la URL son variables altamente correlacionadas con la publicación.

Las secciones representan el único atributo que no resulta completamente exclusivo de cada editorial. Sin embargo, incluso en este caso, aproximadamente

Publicación	**Dominios observados**
Reuters	reuters
CNBC	cnbc
The Hill	thehill
The New York Times	nytimes, blogs.nytimes, cn.nytimes
People	people

Cuadro 4: Dominios característicos identificados por publicación

el 95,6 % de las secciones aparecen únicamente en una sola publicación. En total, 391 de las 409 secciones identificadas pertenecen exclusivamente a una editorial. Esto sugiere que la sección del artículo también constituye un indicador muy fuerte de la editorial, aunque ligeramente menos determinante que el autor o el dominio de la URL.

Sección	**Reuters**	**CNBC**	**NYT**	**People**
Market News	1218	0	0	0
Wires	0	733	0	0
Financials	679	0	0	0
Intel	465	0	0	0
Bonds News	415	0	0	0
world	0	0	329	0
opinion	0	0	319	0
us	0	0	297	0
tv	0	0	0	280
arts	0	0	239	0
crime	0	0	0	130
Tech	0	146	0	0

Cuadro 5: Secciones más frecuentes por publicación

Se investigó la correlación entre la sección y el cuerpo del artículo. Sin embargo, la gran mayoría de los artículos mencionaban distintas secciones dentro del texto, por lo que se decidió estudiar el uso de una misma sección dentro del cuerpo.

La hipótesis planteada fue que, si las secciones aparecen mencionadas dentro del cuerpo del artículo, entonces estas podrían funcionar como pistas identificables del medio o de la estructura editorial del artículo.El cuadro 6 sugiere que la hipótesis es falsa

Publication	Secciones automencionadas
Reuters	1
CNBC	6
The Hill	0
The New York Times	31
People	22

Cuadro 6: Cantidad de seccioens automencionadas por editorial

Se implementó la misma lógica para los autores, pero se observó que únicamente en una ocasión un autor se mencionó a sí mismo dentro de un artículo: **Ghaida Ghantous**.

Otra consideración posible es verificar cuántas veces aparece explícitamente el nombre de la editorial dentro de artículos producidos por ella misma. Sin embargo, ese análisis queda reservado para una segunda etapa del trabajo. Solo se verificó que el nombre de las editoriales estén presentes en los artículos (ver Cuadro 7).

Editorial	Cantidad de artículos
Reuters	12473
The Hill	3550
CNBC	1795
People	934
The New York Times	836

Cuadro 7: Cantidad total de apariciones de editoriales en artículos

2.6. Parte F

Hacer una restricción temporal podría ser util, dado que se observó la presencia de palabras muy utilizadas, como *Trump* o *campaña*. Consideramos que, si se segmentara el análisis en años o momentos clave —por ejemplo, finales de 2019 o durante 2016—, podría observarse una fuerte relación entre dichos artículos y eventos como la pandemia de COVID-19 o las elecciones presidenciales estadounidenses. Esto también podría justificar el aumento progresivo en la publicación de artículos durante 2019.

Pero como se vio anteriormente las secciones son casi exclusivas por editorial. Sin hacer una comparación semántica para clasificar las secciones, no sería útil hacer esta separación. Se podría hacer un trabajo de tagging sobre las secciones a que si bien no son las mismas pueden referirse al mismo tema.

3. Parte II

3.1. Parte A

Usando la función de conteo de palabras, se obtuvo un dataframe por editorial que tiene de índice la palabra y como valor la cantidad de veces que aparece. Al ordenarlas y visualizarlas, se vio que la mayor cantidad de palabras suelen ser palabras que no aportan información al contexto (ver Figura 3). Por lo tanto, se implementó una etapa de filtrado, en la cual se usó un diccionario de palabras no deseadas para filtrar (lista prohibitiva). Los resultados se pueden observar en la Figura 4.

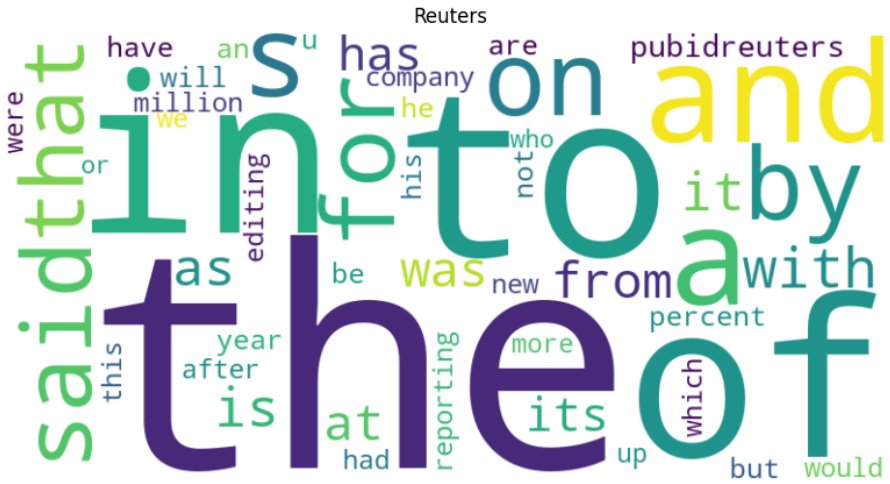

Figura 3: Palabras sin filtrar

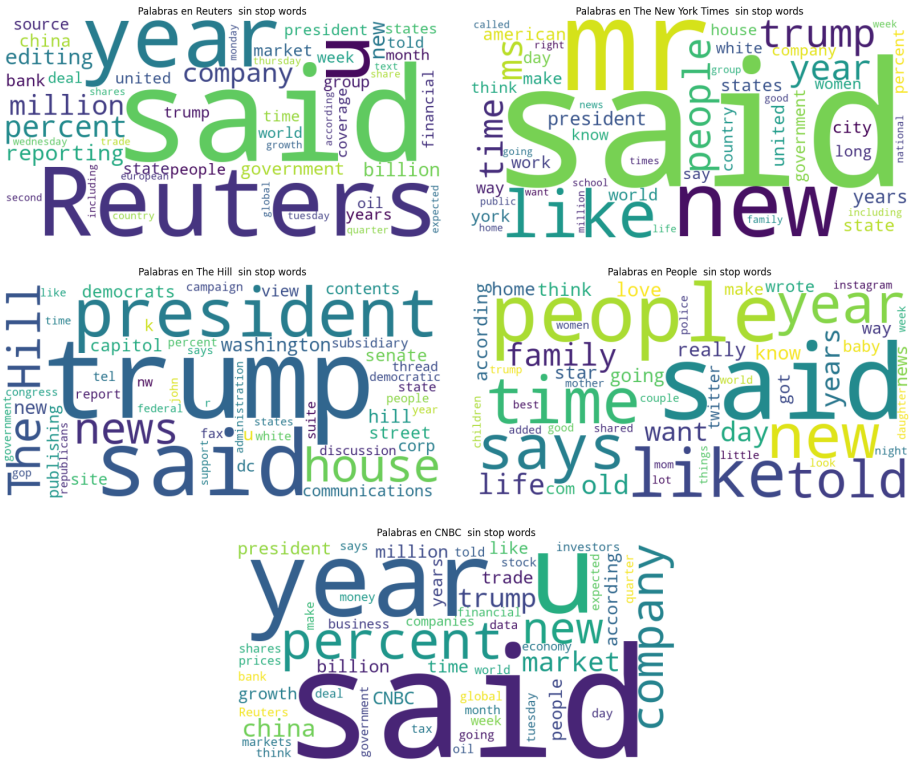

Figura 4: Palabras Filtradas

3.2. Parte B

Para esta parte se ejecutó el código de conteo de palabras para obtener un aproximación de la cantidad total de palabras en artículos de cada editorial.

Teniendo en cuenta que antes se habían reemplazado los nombres de las editoriales durante el preprocesamiento de los datos, lo que introdujo un pequeño error en el conteo final. Para corregirlo, se sumó la cantidad de palabras que contiene el nombre de cada editorial multiplicada por la cantidad de apariciones de la editorial, menos uno. De esta manera se obtuvo una estimación más precisa del total de palabras por medio.

Publicación	**Conteo aproximado**	**Conteo corregido**
Reuters	2 635 437	2 635 464
The New York Times	2 600 065	2 602 000
CNBC	1 215 809	1 215 917
The Hill	1 346 754	1 350 672
People	650 977	651 062

Cuadro 8: Cantidad aproximada de palabras por publicación antes y después de la corrección

3.3. Parte C

Para esta parte se reutilizó la lógica de la sección 1E. Habiendo filtrado previamente los nombres de las editoriales y reemplazándolos por sus respectivos IDs, únicamente fue necesario buscar los IDs en el dataframe obtenido tras realizar el conteo de palabras. Este procedimiento se aplicó tanto para la columna de *artículos* como para la de *títulos*. Podemos ver en la Figura 5 que *People* es mencionada por la mayoría de las editoriales. Esto puede ser un error debido a que no es trivial distinguir el nombre de la editorial de la palabra al principio de una oración.

Otra observación de la Figura 5 es que la editorial *CNBC* menciona en más de mil oportunidades a *Reuters*.

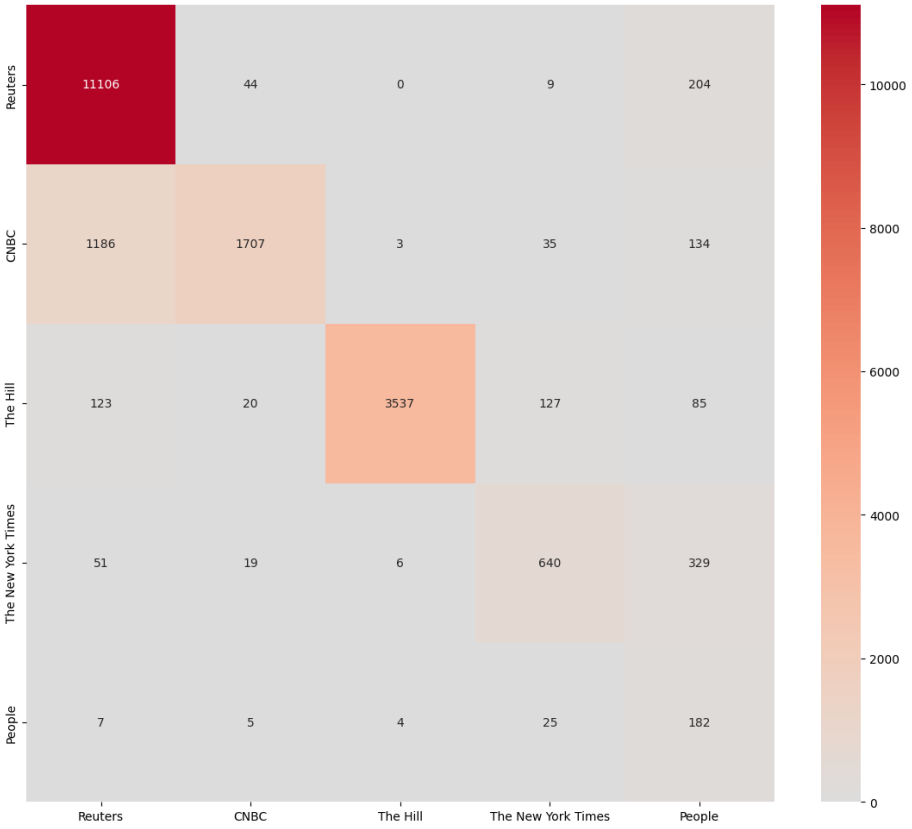

Figura 5: Menciones en artículos

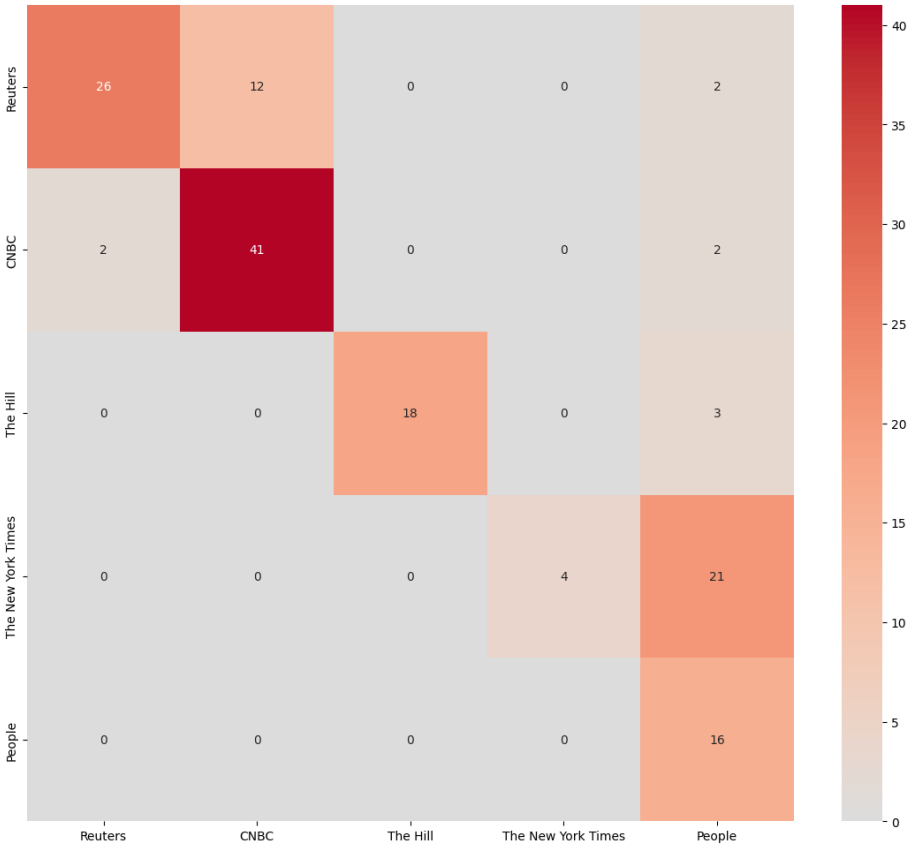

Figura 6: Menciones en títulos

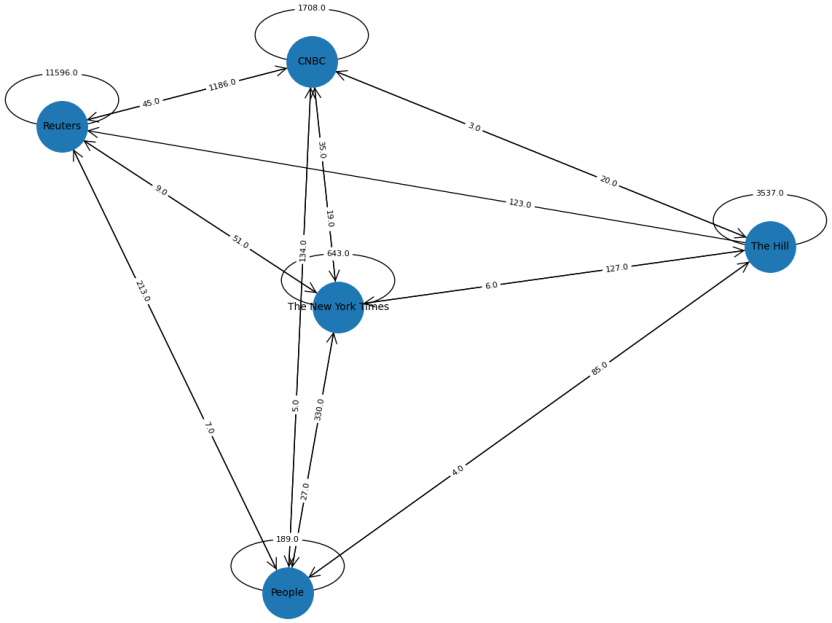

Figura 7: Grafo de relaciones en artículos

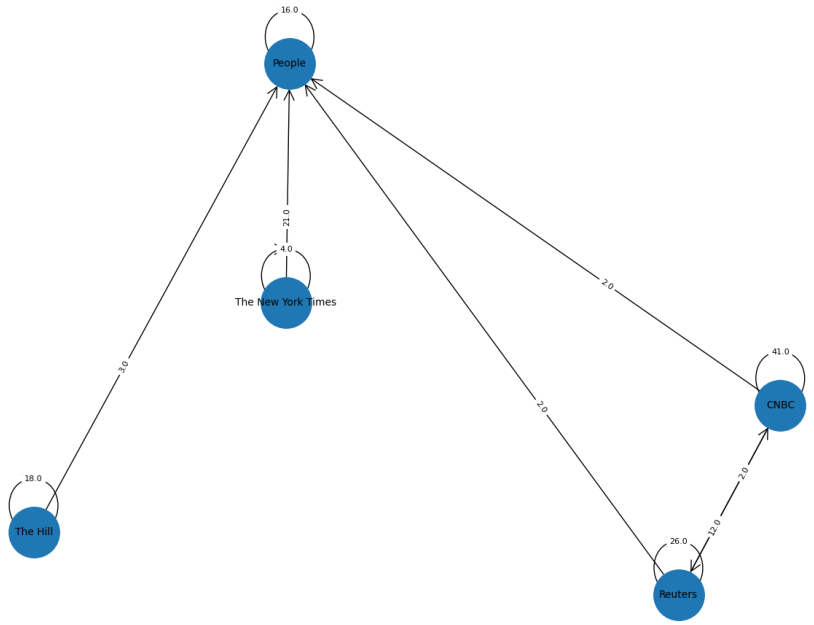

Figura 8: Grafo de relaciones en títulos

3.4. Parte D

Se pensó en el siguiente listado de preguntas para la parte D:

1. Dado únicamente un artículo específico (título + cuerpo), ¿es posible identificar qué editorial lo público?

2. ¿Cuántos artículos similares hay entre las editoriales y a nivel intra-editorial?

3. ¿Existen inconsistencias entre los títulos, los cuerpos y la sección de los artículos?

Para responder la pregunta 1 se puede hacer un modelo de clasificación, donde se tiene como entradas los atributos *title* y *article*, y se tiene como salida la editorial. Para esto se asigna una clase a cada valor distinto de la columna *publication*, la cual sería usada como etiqueta para el entrenamiento y testing del modelo.

Para la pregunta 2 se identificaron diversas formas posibles de abordar el problema. Una de ellas consistía en realizar un *clustering* temporal y temático de los artículos, para posteriormente aplicar algoritmos de clasificación de lenguaje natural que permitieran identificar patrones, relaciones o tendencias dentro de los distintos grupos obtenidos.

Para la pregunta 3, podría clasificarse cada uno de esos campos utilizando algún modelo de lenguaje (LLM) o técnicas de procesamiento de lenguaje natural. Posteriormente, podrían compararse las temáticas, el tono o la intención comunicativa entre el título, el cuerpo y la sección del artículo, permitiendo detectar posibles inconsistencias; por ejemplo, casos en los que el título resulte engañoso o transmita una idea falsa respecto al contenido real del artículo.